

Министерство науки и высшего образования Российской Федерации

Самарский национальный исследовательский университет
имени академика С.П. Королева

Искусственные нейронные сети. Сети прямого распространения.

Методические указания к лабораторной работе № 1
по курсу «НЕЙРОННЫЕ СЕТИ И ГЛУБОКОЕ ОБУЧЕНИЕ»

САМАРА

2026

Составители: д.ф.-м.н., профессор В.В.Мясников
к.т.н. А.Ю.Баврина

УДК 681.3

Искусственные нейронные сети. Сети прямого распространения.

Методические указания к лабораторной работе № 1

Самарский национальный исследовательский университет
имени академика С.П. Королева

Составители: В.В. Мясников, А.Ю.Баврина

Самара, 2026. 20 с.

В лабораторной работе № 1 по курсу «Искусственные нейронные сети. Сети прямого распространения.» изучаются принципы работы и основные функции построения, обучения, оптимизации и оценки качества работы нейронных сетей прямого распространения.

Методические указания предназначены для студентов, обучающихся по специализациям 10.05.03 - "Информационная безопасность автоматизированных систем" и 01.03.02 - "Прикладная математика и информатика".

Печатается по решению редакционно-издательского совета
Самарского национального исследовательского университета
имени академика С.П. Королева

Рецензент: д.ф.-м.н., профессор ФИО

Цель работы: изучить принципы работы и основные функции построения, обучения, оптимизации и оценки качества работы нейронных сетей прямого распространения.

ИСКУССТВЕННЫЕ НЕЙРОННЫЕ СЕТИ. СЕТИ ПРЯМОГО РАСПРОСТРАНЕНИЯ.

Искусственная нейронная сеть (ИНС) - это параметрически заданная функция, реализующая отображение множества входных сигналов во множество выходных с использованием модели, составленной из множества связанных между собой элементов - стандартных формальных нейронов или искусственных нейронов.

1. Стандартный формальный нейрон

Искусственный нейрон имитирует в первом приближении работу биологического нейрона. На вход искусственного нейрона поступает некоторое множество сигналов $x_1, x_2, \dots, x_n$, обозначаемое вектором $\mathbf{x}$, каждый из которых является выходом другого нейрона. Каждый сигнал умножается на соответствующий вес $w_1, w_2, \dots, w_n$, аналогичный "синаптической силе" биологической связи, и поступает на суммирующий блок, обозначенный Σ на рисунках 1 а и 1 б. Суммирующий блок складывает взвешенные входы алгебраически, создавая выход, который обозначается "s". В векторных обозначениях преобразование может быть записано следующим образом:

$$s = \bar{\mathbf{w}}^T \bar{\mathbf{x}}.$$

Этот элемент искусственного нейрона носит название адаптивный сумматор. *Адаптивный сумматор* вычисляет скалярное произведение вектора входного сигнала $\mathbf{x}$ на вектор параметров. Адаптивным его называют из-за наличия вектора настраиваемых параметров. Последним преобразованием в искусственном нейроне является нелинейное преобразование выхода сумматора, которое выполняется *активационной функцией* нейрона (рисунок 1 в). Окончательно, работа формального нейрона описывается следующим выражением:

$$y = f(s) = f(\bar{\mathbf{w}}^T \bar{\mathbf{x}}).$$

Точка ветвления, показанная на рисунке 1 г, служит для рассылки выходного сигнала одного нейрона по другим нейронам ИНС. Она получает скалярный входной сигнал y и

передает его всем своим выходам. Таким образом, *стандартный формальный нейрон* составлен из входного сумматора, нелинейного преобразователя и точки ветвления на выходе, как показано на рисунке 1 д.





Рис. 1 – К определению формального нейрона как элемента ИНС

Важным моментом при построении ИНС является нелинейность функции активации нейрона. К ней обычно предъявляют следующие требования:

- является монотонно возрастающей;
- первая производная существует почти всюду,
- производная легко вычисляются через значения самой функции.

Наиболее типичными активационными функциям являются:

рациональная сигмоида $f(S)=\frac{S}{ S +a} \quad \text{или} \quad f(S)=a_1 \frac{S}{ S +a_2} + a_3$	
логистическая функция (или функция Ферми) $f(S)=\frac{1}{1+e^{-S}} \quad \text{или} \quad f(S)=\frac{1}{1+e^{-2aS}}$	

ReLU $f(s) = \begin{cases} s, & s \geq 0; \\ 0, & s < 0. \end{cases}$	
Leaky ReLU $f(s) = \begin{cases} s, & s \geq 0; \\ 0.01s, & s < 0. \end{cases}$	

2. Архитектуры ИНС

Несмотря на то, что вариантов построения ИНС из указанных элементов множество, их все обычно можно поделить на две базовые группы: *слоистые и полносвязные сети*. При этом, если функция активации во всех нейронах ИНС одинакова, то такую сеть называют *однородной (гомогенной)*. Если же f зависит еще от одного или нескольких параметров, значения которых меняются от нейрона к нейрону, то сеть называют *неоднородной (гетерогенной)*.




Рис. 2 – Многослойная ИНС или многослойный перцептрон

В *слоистых или многослойных сетях* нейроны расположены в несколько слоев, как показано на рисунке 2. Нейроны первого слоя получают входные сигналы, преобразуют их и через точки ветвления передают нейронам второго слоя. Далее срабатывает второй слой и т.д. до k -го слоя, который выдает выходные сигналы для интерпретатора и пользователя. Если не оговорено противное, то каждый выходной сигнал i -го слоя подается на вход всех нейронов $i+1$ -го. Число нейронов в каждом слое может быть любым и никак заранее не связано с количеством нейронов в других слоях. Стандартный способ подачи входных сигналов: все нейроны первого слоя получают каждый входной сигнал. Формальное выражение прохождения сигнала для всех нейронов, начиная с первого слоя до последнего $n=1, 2, 3, \dots, N$ имеет вид:

$$S_j^{(n)} = \sum_{i \in I_{(n-1)}} w_{ij}^{(n)} y_i^{(n-1)}, \quad y_j^{(n)} = f\left(S_j^{(n)}\right), \quad (1)$$

Здесь N – число слоев ИС, I_n – множество нейронов в n -ом слое ($n = \overline{1, N}$), w_{ij}^n – синаптический вес j -го нейрона слоя n от i -ого нейрона слоя $n-1$, ($i \in I_{n-1}, j \in I_n$); $y_j^{(n)}$ – выход активационной функции j -го нейрона n -го слоя, $S_j^{(n)}$ – выход сумматора j -го нейрона n -го слоя. Дополнительно, $y_j^{(0)} = x_j$ – входные сигналы, поступающие на вход нейронов первого слоя ($j \in I_0$), $y_j^{(N)}$ – выходные значения сети ($j \in I_N$).

Особое распространение получили трехслойные сети, в которых каждый слой имеет свое наименование: первый – входной, второй – скрытый, третий – выходной.

В *полносвязных сетях* каждый нейрон передает свой выходной сигнал остальным нейронам, включая самого себя (рисунок 3). Выходными сигналами сети могут быть все или некоторые выходные сигналы нейронов после нескольких тактов функционирования сети (под *тактом* здесь понимается прохождение сигнала через один слой). Все входные сигналы подаются всем нейронам. Формальное выражение перерасчета сигналов нейронов от такта $(t-1)$ к такту t имеет вид:

$$y_j(t) = f\left(\sum_{i \in I} w_{ij} y_i(t-1)\right), \quad j \in I$$

Если полносвязная сеть функционирует до получения ответа заданное число тактов k , то ее можно представить как частный случай k -слойной ИНС, все слои которой одинаковы и каждый из них соответствует такту функционирования полносвязной сети.

Существенное различие между полносвязной и слоистой сетями возникает тогда, когда число тактов функционирования заранее не ограничено – в таком случае слоистая сеть работать не может.




Рис. 3 – Полносвязная ИНС

Наряду с указанными группами сетей еще рассматривают смешанный вариант, так называемые рекуррентные сети. В общем случае, *рекуррентной сетью* – это любая ИНС, где есть обратные связи. То есть любая ИНС, не являющаяся слоистой, может быть определена как рекуррентная. Однако на практике часто под рекуррентной понимают слоистую сеть, где между некоторыми слоями существуют обратные связи.

3. Теоремы существования решений в рамках нейронных сетей

Этот раздел посвящен вопросу, какие функции можно представить с помощью конструкций, входящих в состав нейронных сетей.

Вообще вопросом представления функций (в частности, непрерывных функций) занимались задолго до появления искусственных нейронных сетей.

Теорема Колмогорова дает ответ на вопрос, можно ли представить функцию нескольких переменных с использованием функций меньшего числа переменных.

Теорема Колмогорова-Арнольда (1957):

Каждая непрерывная функция n переменных, заданная на единичном кубе n -мерного пространства, представима в виде

$$f(x_1, x_2, \dots, x_n) = \sum_{q=1}^{2n+1} h_q \left[\sum_{p=1}^n \varphi_q^p(x_p) \right],$$

где функции $h_q(u)$ непрерывны, а функции $\varphi_q^p(x_p)$, кроме того, еще и стандартны, т.е. не зависят от выбора функции f .

В частности, каждая непрерывная функция двух переменных x, y представима в виде:

$$f(x, y) = \sum_{q=1}^5 h_q [\phi_q(x) + \psi_q(y)].$$

Теорема Колмогорова, очевидно, в неконструктивной форме доказывает существование НС (рисунок 4), которая *точно* решает задачу представления функции, причем указана архитектура сети (3-х слойная) и минимальное число нейронов – вот почему так популярны 3-х слойные сети. Остается проблема найти эти функции h и φ .




Рис. 4 – ИНС, решающая задачу Колмогорова

До сих пор речь шла о точном представлении функций многих переменных с помощью функций одного переменного. Оказалось, что в классе непрерывных функций такое представление возможно. Но кроме вопроса о точном представлении существует еще один – об аппроксимации. Можно даже предположить, что он важнее – вычисление большинства функций производится приближенно даже при наличии «точных» формул.

Приближение функций многочленами и рациональными функциями имеет историю, еще более давнюю, чем проблема точного представления. Вспомним знаменитую *теорему Вейерштрасса*. Но сначала вспомним некоторые понятия из алгебры и математического анализа.

Множество ограничено, если его диаметр конечен.

Множество замкнуто, если оно содержит все свои предельные точки.

Например, множество действительных чисел отрезка $[a, b]$ ограничено и замкнуто. А множество чисел отрезка (a, b) ограничено, но не замкнуто.

Компакт – это обобщенное понятие для замкнутых и ограниченных множеств.

Алгебра – это множество с введенными операциями (операцией) над элементами множества. Алгебра всегда является замкнутой в алгебраическом смысле относительно своих операций (результат операции над элементами множества принадлежит множеству). Но алгебра может быть незамкнутой в топологическом смысле. Например, в алгебре многочленов произведения многочленов – это многочлены, но если рассмотреть сходящуюся последовательность многочленов, то она может сходиться к синусу, который многочленом не является.

При рассмотрении нормы функций чаще всего используют понятие *равномерной нормы* как максимального по модулю значения функции. Это обеспечивает близость функций в каждой точке, в отличие от среднеквадратичной нормы, где близость будет в среднем (а максимальная может быть гораздо больше).

Теорема Вейерштрасса (аппроксимационная, 1885г.) *Непрерывную функцию нескольких переменных $f(x_1, x_2, \dots, x_n)$ на замкнутом ограниченном множестве Q можно равномерно приблизить последовательностью полиномов: для любого $\varepsilon > 0$ существует такой многочлен r -ой степени $P_r(x_1, x_2, \dots, x_n)$, что*

$$\sup_Q |f(x_1, x_2, \dots, x_n) - P_r(x_1, x_2, \dots, x_n)| < \varepsilon.$$

В более абстрактных понятиях это означает, что множество многочленов *плотно* в множестве непрерывных функций на замкнутом ограниченном множестве.

Обобщение теоремы Вейерштрасса было дано *Стоуном*. Он задался вопросом, какими еще функциями, кроме полиномов, можно приближать непрерывные функции? Но перед этим – еще несколько понятий.

Функция f разделяет точки в пространстве X если для любых $y \in X$, $x \neq y$ и x выполняется $f(x) \neq f(y)$.

Алгебра содержит *единицу* когда существует элемент множества, нейтральный по отношению к операции, введенной в алгебре.

Теорема Стоуна (1935г.) *Пусть X – компактное топологическое пространство, $C(X)$ – множество непрерывных функций на X с действительными значениями. Пусть*

также $E \subseteq C(X)$ – замкнутая подалгебра (множество непрерывных функций, замкнутое относительно сложения, умножения и умножения на число), которая содержит единицу и функции в ней разделяют точки. Тогда E плотно в пространстве $C(X)$ (более формально, $\overline{E} = C(X)$).

То есть любую непрерывную на отрезке функцию можно равномерно приблизить не просто многочленами, а любыми непрерывными функциями, разделяющими точки.

Проверим применимость этой теоремы для функций, реализуемых с помощью нейронных сетей.

1. Условие, что класс функций, вычисляемых нейронными сетями, замкнут относительно линейных операций и операции умножения (то есть результаты этих операций также могут быть реализованы НС).

Пусть нейронные сети $S_1, S_2, \dots, S_k$, реализуют вычисление функций $F_1, F_2, \dots, F_k$, тогда линейная комбинация $\alpha_0 + \alpha_1 F_1 + \alpha_2 F_2 + \dots + \alpha_k F_k$ вычисляется, подавая на вход новой сети с весами $\alpha_0, \alpha_1, \alpha_2, \dots, \alpha_k$ значения $S_1, S_2, \dots, S_k$.

Для доказательства замкнутости относительно умножения, представим произведение таким образом: $F_1 * F_2 = \frac{1}{2}((F_1 + F_2)^2 - F_1^2 - F_2^2)$. Очевидно, такое произведение может быть реализовано на основе комбинации нейросетей с квадратичной активационной функцией.

2. Условие наличия единицы. Нейросеть с единичным весом, нулевым смещением и тождественной активационной функцией будет являться единичной нейросетью.

3. Условие существования функции, разделяющей точки. Пусть $\bar{a}, \bar{b} \in R^n$ – точки, которые необходимо разделить при помощи функции $f(x)$, реализуемой нейросетью. Представим её в виде разделяющей границы классификатора Байеса: $f(x) = (a - b)^T x - \frac{1}{2}(a + b)^T(a - b)$. Такая функция может быть реализована нейросетью с весами $(a - b)$, смещением $(-\frac{1}{2}(a + b)^T(a - b))$ и тождественной активационной функцией.

Разница значений функций $f(a) - f(b) = (a - b)^T(a - b) \neq 0$ для $a \neq b$.

Условия теоремы Стоуна выполнены, следовательно, множество функций, вычисляемых нейронными сетями, плотно в пространстве непрерывных на компакте функций.

4. Обучения ИНС. Алгоритм обратного распространения ошибки

Одним из наиболее известных алгоритмов обучения ИНС является алгоритм обратного распространения ошибки, относящийся к классу алгоритмов стохастического градиента, который для слоистой однородной ИНС с логистической активационной функцией представим в виде.

Алгоритм обратного распространения ошибки

1. Задать значения весов ИНС случайным образом в диапазоне $[-1,1]$.
2. Подать на вход сети k -й образец и рассчитать значения выходов нейронов начиная с 1-го слоя до последнего по формуле (1). На основании полученных значений выходов $y_j^{(n)}$ выполняется шаг 3. Здесь d_j – требуемые значения выходов.
3. Рассчитать значения ошибки $g_j^{(n)}$ (при обработке k -го образца) по формуле (начиная с $n=N$ и до 1):

* для $n=N$

$$g_j^N = y_j^N (1 - y_j^N) (d_j - y_j^N), \quad (2)$$

* для $n < N$

$$g_j^n = \underbrace{y_j^n (1 - y_j^n)}_{(n)} \cdot \sum_{i \in I_{n+1}} g_i^{(n+1)} w_{ji}^{(n+1)}. \quad (3)$$

4. Скорректировать веса $w_{ij}^{(n)}$ (по k -ому образцу):

$$w_{ij}^{(n)} = w_{ij}^{(n)} (k-1) - \rho g_i^n \cdot y_i^{(n-1)}. \quad (4)$$

5. Протестировать работу сети – это может выполняться периодически через некоторое количество шагов. Если ошибка существенна, то go to 1. В противном случае конец.

Примечание. Сети попеременно предъявляются все тренировочные образцы в случайном порядке. Это гарантирует, что сеть не будет настраиваться на образцы с определенными свойствами, «забывая» при этом остальные образцы.

5. Результаты

В представленных методических указаниях кратко представлены основы

искусственных нейронных сетей. Под искусственной нейронной сетью (ИНС) мы понимаем параметрически заданную функцию, реализующую отображение множества входных сигналов во множество выходных с использованием модели, составленной из множества связанных между собой элементов - *стандартных формальных нейронов или искусственных нейронов*. Представлены основные архитектуры ИНС: слоистые, полносвязные и рекуррентные. Для слоистых сетей изложен алгоритм обратного распространения ошибки (без доказательства). Представленный материал достаточен для первичного знакомства с понятиями ИНС и может использоваться как краткое введение в тему для тех, кто намерен начать изучать данный предмет.

ЛИТЕРАТУРА

1. Уоссермен Ф. Нейрокомпьютерная техника: Теория и практика. М.: Мир, 1992
2. Станислав Осовский «Нейронные сети для обработки информации», М. «Финансы и статистика», 2002, 344с.
3. Горбань А.Н. Обучение нейронных сетей. М.: изд. СССР-США СП "ПараГраф", 1990. 160 с.
4. Хайкин С. «Нейронные сети. Полный курс», 2006
5. Гудфеллоу Я., Бенджио И., А.Курвиль Глубокое обучение, ДМК Пресс, 2017
6. Николенко С., Кадурын А., Архангельская Е. Глубокое обучение. — СПб.: Питер, 2018. — 480 с.: ил.
7. Бишоп К. М., Бишоп Х. Глубокое обучение: принципы и концепции, ДМК Пресс, 2025.
8. Принс Саймон Машинное обучение. От основ до продвинутых моделей (серия - Библиотека MIT), 2025.

ПОРЯДОК ВЫПОЛНЕНИЯ ЛАБОРАТОРНОЙ РАБОТЫ

Исходные данные

набор данных mnist (рукописные цифры)

Общий план выполнения работы

1. Загрузить набор данных mnist (рукописные цифры) из tensorflow.keras. Вывести на экран по 1-му изображению на каждую цифру из обучающего набора. Для дальнейшей работы нормализовать изображения из обучающей и тестовой выборки (разделить на 255). В качестве признаков использовать изображение, вытянутое в вектор (длина полученного вектора 28×28).
2. Реализовать программно обучение нейронной сети с 1-м или 2-мя скрытыми слоями (число нейронов задается параметрами). При обучении 20% обучающей выборки отложить на валидацию. Заложить возможность использовать dropout.
3. Провести обучение нейронной сети (количество скрытых слоев, нейронов в них, значения «dropout», «batch_size» и т.д. задать самостоятельно в разумных пределах) в течение 15-20 эпох. Визуализировать зависимость функции потерь и критерия качества от номера эпохи для обучающей и валидационной выборок. Вывести на экран структуру модели и количество обучаемых параметров, убедиться, что все данные соответствуют желаемому.
4. Провести классификацию тестовой выборки, вычислить оценочное значение критерия качества и функции потерь (с использованием функции evaluate). Вычислить отдельно confusion matrix, вычислить по ней критерий качества и сравнить его значение со значением, полученным ранее. Отобразить на экране по одному изображению на каждый класс, проклассифицированному неверно.
5. Исследовать динамику обучения модели в зависимости от изменения значений параметров «dropout» («0», «0.1», «0.2», «0.3») и «batch_size» («16», «32», «64», «128») по отдельности. Для этого при фиксированном значении одного параметра обучить модель для нескольких значений другого параметра. Визуализировать историю обучения (зависимость функции потерь от номера эпохи для обучающей

и валидационной выборки), по графикам сделать вывод о влиянии этих параметров на динамику обучения.

6. Организовать поиск оптимальных значений числа нейронов и параметра `batch_size` для сети с **одним** скрытым слоем с помощью поиска по сетке параметров с использованием функции «GridSearchCV» (с разумными значениями). Вывести значения найденных параметров.
7. Выписать аналитическое выражение для количества весовых коэффициентов модели для сети с 1-м и 2-мя скрытыми слоями в зависимости от числа нейронов на этих слоях (число нейронов задается в качестве переменных). Исследовать целесообразность усложнения модели при сохранении количества обучаемых параметров. Для этого провести обучение сети с **одним** и **двумя** скрытыми слоями, имеющими **одинаковое** (примерно) количество параметров (выбрать в пределах 70 000-100 000). Сделать выводы.

Используемые функции

- `tensorflow.keras.models.Sequential()` – класс библиотеки `keras`, позволяющий создавать модели с последовательным добавлением слоёв. Для создания модели можно либо перечислять нужные слои в определенной последовательности в конструкторе, либо добавлять слои постепенно, используя метод `add()`, либо последовательно вызывать эти слои, передавая результаты предыдущих слоёв в качестве входного параметра.

`Input` – входной слой (передается размерность входных данных).

`Dense` – полносвязанный слой (передать число нейронов и вид функции активации). Активационные функции использовать «gelu» для скрытых слоев и «softmax» для выходного слоя.

`Dropout` –случайным образом «выключает» (обнуляет) часть нейронов во время обучения для предотвращения переобучения (передается доля обнуляемых нейронов).

После задания слоёв модели необходимо скомпилировать модель. Компилировать модель со следующими параметрами: функция потерь –

`SparseCategoricalCrossentropy` (в этом случае можно использовать непосредственно номер класса при обучении), оптимизатор – 'adam', критерий качества (отслеживаемая метрика) – 'acc'.

- `nn_model.fit(...)` – обучение модели. Здесь можно указать процент обучающей выборки, откладываемой для валидации. Параметр `batch_size` задает, сколько экземпляров обучающих данных будет обработано перед обновлением весов модели. Функция возвращает историю обучения, которую можно визуализировать.
- `nn_model.evaluate(...)` – оценка функции потерь и критерия качества на обученной модели.
- `nn_model.summary()` – вывод структуры и количества параметров модели.
- `nn_model.predict(...)` – классификация обученной моделью.
- `sklearn.metrics.confusion_matrix(...)` – построение матрицы путаницы (`confusion_matrix`) на основе сравнения истинных значений меток и результатов классификации.
- `sklearn.model_selection.GridSearchCV(...)` – оптимизация по гиперпараметрам, задаваемым в виде узлов сетки. С помощью параметра 'cv' задается количество разбиений при выполнении обучения с кроссвалидацией.

КОНТРОЛЬНЫЕ ВОПРОСЫ

1. Определение формального нейрона как элемента ИНС: схема, структурные единицы, формула, виды активационных функций и требования к ним.
2. Архитектуры ИНС: слоистые и полносвязные сети, их схемы и формальные выражения работы.
3. Теоремы существования решений в рамках нейронных сетей: теорема Колмогорова-Арнольда, теорема Вейерштрасса, теорема Стоуна, доказательство применимости теоремы Стоуна к множеству функций, вычислимых нейронными сетями.
4. Алгоритм обратного распространения ошибки для слоистой однородной ИНС.

СОДЕРЖАНИЕ

Искусственные нейронные сети. Сети прямого распространения.....	3
1. Стандартный формальный нейрон	3
2. Архитектуры ИНС.....	5
3. Теоремы существования решений в рамках нейронных сетей	7
4. Обучения ИНС. Алгоритм обратного распространения ошибки.....	11
5. Результаты.....	11
Литература	12
Порядок выполнения лабораторной работы	13
Исходные данные	13
Общий план выполнения работы.....	13
Используемые функции.....	14
Контрольные вопросы	15
Содержание	16

Учебное издание

Искусственные нейронные сети. Сети прямого распространения

Методические указания к лабораторной работе № 1 по курсу «Нейронные сети и глубокое обучение»

Составители: Мясников Владислав Валерьевич

Баврина Алина Юрьевна

Самарский национальный исследовательский университет

имени академика С.П. Королева

443086, Самара, Московское шоссе, 34

Отпечатано на кафедре «Геоинформатика и информационная безопасность»

Тираж 20 экз.